

Sistema de Detección de Hongos y Síntomas de Nemátodos en Hojas de Papa Mediante Visión Artificial y Aprendizaje Profundo

Jesús Escudero Álvarez

Ingeniería Electrónica

Universidad de Sucre – Sincelejo, Colombia

jesusdavidescuderoalvarez@gmail.com

Lucas Rivadeneira Zarza

Ingeniería Electrónica

Universidad de Sucre – Sincelejo, Colombia

lucas.rivadeneira@unisucrevirtual.edu.co

Junio, 2026

Resumen

Este documento presenta el desarrollo, entrenamiento y validación de un modelo de clasificación de imágenes de hojas de papa basado en aprendizaje profundo. El sistema identifica cuatro estados fitosanitarios: hojas sanas, tizón tardío (*Phytophthora infestans*), tizón temprano (*Alternaria solani*) y síntomas foliares asociados a nemátodos (*Globodera pallida*). El modelo, basado en la arquitectura EfficientNet-B0 con transfer learning en dos fases, se entrenó y evaluó sobre un conjunto de imágenes foliares organizado mediante técnicas de balanceo de clases, alcanzando una exactitud global de 98.44 % en el conjunto de prueba. Adicionalmente, se realizó un experimento de control con tres clases (excluyendo nemátodos) para aislar el efecto del desbalance severo de esta categoría sobre el desempeño general del sistema. Los resultados obtenidos evidencian la viabilidad de esta solución para el contexto agrícola del departamento de Sucre, Colombia, donde no existían previamente herramientas automatizadas de bajo costo para el diagnóstico fitosanitario temprano.

1. Introducción

El cultivo de papa (*Solanum tuberosum* L.) ocupa el cuarto lugar entre los alimentos más importantes del mundo [1] y constituye un pilar fundamental de la seguridad alimentaria y la economía agrícola en Colombia. Con más de 350.000 empleos directos e indirectos generados en el país, este cultivo concentra su producción en regiones andinas y representa una fuente crítica de ingresos para miles de familias rurales [2]. Más allá de su importancia económica, la papa combina alto valor nutricional con creciente demanda en mercados globales, posicionándola como estratégica para la sostenibilidad alimentaria.

Sin embargo, la productividad se ve comprometida por diversas enfermedades fitopatológicas que generan pérdidas económicas significativas. Entre las más importantes se encuentran el tizón tardío causado por *Phytophthora infestans*, el tizón temprano ocasionado por *Alternaria solani* y los nemátodos quiste (*Globodera pallida*). El tizón tardío es considerado una de las enfermedades más destructivas del cultivo de papa debido a su rápida propagación y capacidad para ocasionar pérdidas severas en cortos periodos de tiempo [3]. Por su parte, el tizón temprano afecta principalmente el follaje mediante lesiones necróticas concéntricas características que reducen la capacidad fotosintética de la planta y pueden ocasionar pérdidas significativas de rendimiento cuando no se implementan medidas de control oportunas [4, 5]. Asimismo, los nemátodos quiste ocasionan daños en el sistema radicular que afectan la absorción de agua y nutrientes, comprometiendo el desarrollo normal de la planta [6]. Estas enfermedades son responsables de reducciones de rendimiento superiores al 48 % incluso a bajas densidades de infestación, se pueden visualizar en la Fig. 1a , Fig. 1b y la Fig. 1c.



(a) Tizón tardío (*Phytophthora infestans*). (b) Tizón temprano (*Alternaria solani*). (c) Nemátodo quiste (*Globodera pallida*).

Figura 1: Principales enfermedades y plagas que afectan el cultivo de papa.

El diagnóstico actual depende principalmente de inspecciones visuales subjetivas realizadas por expertos, proceso que resulta lento, no escalable y de difícil acceso en zonas rurales con limitada asistencia técnica [7].

En respuesta a esta problemática, técnicas de visión artificial y aprendizaje profundo han emergido como alternativas viables. Arquitecturas de redes neuronales convolucionales (CNN) entrenadas sobre datasets públicos de imágenes foliares han demostrado alcanzar precisiones superiores al 90 % en clasificación de enfermedades vegetales [8, 9]. Estos sistemas ofrecen la posibilidad de automatizar diagnósticos, reducir costos operacionales y fortalecer esquemas de agricultura de precisión.

El presente proyecto diseñó, entrenó y validó un modelo de clasificación de imágenes basado en aprendizaje profundo, capaz de distinguir cuatro estados fitosanitarios en hojas de papa: hoja sana, tizón tardío (*Phytophthora infestans*), tizón temprano (*Alternaria solani*) y síntomas foliares asociados a nemátodos. Mediante técnicas de visión artificial, el sistema desarrollado facilita la detección temprana de estas afecciones, contribuyendo a la implementación oportuna de estrategias de manejo fitosanitario y al fortalecimiento de la productividad agrícola en contextos de pequeños productores.

2. Planteamiento del Problema

A escala global, la papa se cultiva en aproximadamente 18 millones de hectáreas, generando una producción que en 2023 superó los 375 millones de toneladas [10]. Pese a su importancia estratégica, el cultivo enfrenta pérdidas significativas por enfermedades fúngicas y parasitarias. Los oomicetos como *Phytophthora infestans* y nemátodos como *Globodera* representan amenazas críticas a nivel mundial, con capacidad de reducir severa y dramáticamente el rendimiento [11–13].

En Colombia, el panorama es particularmente crítico. El cultivo aporta el 3,3 % del PIB Agropecuario Nacional, concentrado en nueve departamentos andinos, con 125.000 hectáreas sembradas y una producción de 2.780.000 toneladas anuales para 2020, que generan más de 350.000 empleos directos e indirectos [2, 14]. El nemátodo *Globodera pallida* fue detectado en 1971 en Nariño y hoy se distribuye en los principales departamentos productores, con densidades de 50 a 80 quistes por 100 gramos de suelo [15–17]. Paralelamente, el tizón tardío causado por *Phytophthora infestans* genera las mayores pérdidas económicas en el cultivo nacional [18]. Asimismo, el tizón temprano ocasionado por *Alternaria solani* constituye una de las enfermedades foliares más importantes del cultivo de papa, afectando la capacidad fotosintética de las plantas mediante lesiones necróticas características y provocando reducciones significativas en el rendimiento y la calidad de la producción cuando no es detectado y controlado oportunamente [4, 5].

Aunque el departamento de Sucre no es región papera tradicional, su actividad agrícola diversa en los Montes de María incluye cultivos de tubérculos y raíces donde patógenos similares pueden prosperar. El Plan Departamental de Extensión Agropecuaria 2024 reporta que la producción agrícola sufre impactos significativos por fenómenos climáticos y, críticamente, por la ausencia de herramientas tecnológicas accesibles para diagnóstico fitosanitario [19]. Esta carencia representa una brecha concreta que limita la capacidad de respuesta de productores locales ante enfermedades emergentes o presentes en el suelo.

El problema radica en que no existe, para el contexto sucreño, una herramienta de bajo costo, fácilmente desplegable y fundamentada en inteligencia artificial que permita a pequeños productores diagnosticar automáticamente el estado fitosanitario de sus cultivos, especialmente para distinguir síntomas foliares de enfermedades fúngicas versus daños ocasionados por nemátodos parasíticos.

3. Pregunta Problema

¿En qué medida un modelo de aprendizaje profundo basado en visión artificial permite detectar tempranamente enfermedades fúngicas y síntomas foliares de nemátodos en el cultivo de papa, facilitando a pequeños productores y técnicos del departamento de Sucre la implementación oportuna de estrategias de manejo fitosanitario que reduzcan pérdidas de rendimiento?

4. Justificación

La justificación de este proyecto se fundamenta en la importancia estratégica del cultivo de papa a escala global y nacional. A nivel mundial se cultivan aproximadamente 18 millones de hectáreas con producción que en 2023 superó los 375 millones de toneladas [10], mientras que en Colombia el cultivo aporta el 3,3 % del PIB Agropecuario Nacional y genera más de 350.000 empleos [2,14]. Las enfermedades fitopatógenas ocasionan pérdidas de rendimiento superiores al 48 %, representando un impacto crítico en la seguridad alimentaria nacional y en el bienestar de familias rurales que dependen de este cultivo como fuente primaria de ingresos [3,6,11,12].

El diagnóstico temprano es la primera línea de defensa contra estas patologías, sin embargo, los métodos actuales basados en inspecciones visuales resultan lentos, subjetivos y de difícil acceso en zonas rurales donde pequeños productores carecen de asistencia técnica especializada [7,20]. Afortunadamente, la disponibilidad de datasets públicos como el Multi-Crop Leaf Disease Dataset y plataformas computacionales accesibles como Google Colab y Roboflow permiten entrenar modelos de redes neuronales convolucionales sin inversión significativa [8,21]. Estudios demuestran que estos modelos alcanzan desempeños superiores al 90 % en clasificación de enfermedades vegetales, evidenciando la viabilidad técnica de esta solución [7–9].

El departamento de Sucre presenta vulnerabilidad agrícola por acceso limitado a tecnología especializada de diagnóstico, por lo que un sistema automatizado, de bajo costo y desplegable en dispositivos móviles fortalecería significativamente la capacidad de respuesta de técnicos y productores [19]. Finalmente, la incorporación de síntomas foliares asociados a nemátodos constituye un aporte original, ya que la mayoría de sistemas se enfocan únicamente en patologías fúngicas. La selección de arquitecturas de aprendizaje profundo se justifica por su superioridad en identificar patrones visuales complejos: mientras modelos tradicionales requieren ingeniería manual de características, las CNN aprenden automáticamente representaciones jerárquicas capaces de adaptarse a variaciones en iluminación, ángulos de captura y geometría irregular de hojas, aspecto crítico para precisión diagnóstica en campo [7,8].

5. Objetivos

5.1. Objetivo General

Desarrollar un sistema basado en visión artificial y aprendizaje profundo para la detección de hongos y síntomas foliares de nemátodos en hojas de papa, orientado al diagnóstico fitosanitario temprano en el contexto agrícola del departamento de Sucre.

5.2. Objetivos Específicos

1. Realizar una revisión bibliográfica sobre enfermedades foliares en papa y modelos de aprendizaje profundo aplicados a la agricultura.
2. Diseñar un sistema de clasificación de imágenes para detectar hongos y síntomas foliares de nemátodos en hojas de papa.
3. Evaluar el desempeño del sistema mediante pruebas experimentales en condiciones reales.

6. Metodología

La metodología se organiza en torno a dos experimentos paralelos que comparten infraestructura de datos y arquitectura base, pero difieren en el número de clases objetivo. El Experimento A aborda la clasificación de cuatro categorías: hoja sana, tizón tardío (*Phytophthora infestans*), tizón temprano (*Alternaria solani*) y síntomas foliares de nemátodos. El Experimento B replica el mismo protocolo sobre las tres primeras categorías, excluyendo nemátodos. Esta estructura permite una comparativa directa y controlada sobre el efecto del desbalance severo de clases en el rendimiento del modelo, dado que ambos experimentos operan sobre exactamente las mismas imágenes de tizón tardío, tizón temprano y hoja sana.

6.1. Adquisición y organización del dataset

El conjunto de imágenes se construyó a partir de la integración de cuatro fuentes públicas verificables.¹ El Multi-Crop Leaf Disease Dataset [21] aportó la totalidad de la clase de nemátodos, además de un subconjunto de imágenes de hoja sana y tizón tardío. Para la clase de nemátodos, el dataset contaba originalmente con 68 imágenes; dado que varias de estas fotografías contenían más de una hoja, se realizó un recorte manual individual de cada hoja presente, ampliando el conjunto utilizable a 90 muestras. Las clases hoja sana, tizón tardío y tizón temprano se completaron combinando PlantVillage [22], el dataset “Potato Leaf (Healthy and Late Blight)” [23] y un conjunto adicional de imágenes disponible en Roboflow Universe [24], filtrando de este último las imágenes duplicadas o generadas por augmentation (identificadas mediante coincidencia de nombre de archivo y sufijos `_aug/aug_`), y conservando una única imagen por cada grupo de variantes aumentadas con el mismo índice base. Tras esta integración y deduplicación, el conteo final por clase fue: 1.560 imágenes de hoja sana, 2.593 de tizón tardío, 90 de nemátodos y 2.303 de tizón temprano, evidenciando un marcado desbalance en la clase de nemátodos frente a las demás.

6.2. Balanceo de la clase minoritaria

Dado el marcado desbalance de nemátodos, se aplica data augmentation exclusivamente sobre la clase 2 para elevar su volumen de 90 a 500 imágenes. En cada imagen generada se selecciona aleatoriamente una de las siguientes transformaciones, diseñadas para preservar la información cromática diagnóstica:

- Rotación horizontal.
- Rotación vertical.
- Rotación aleatoria de $\pm 30^\circ$ con relleno negro en esquinas.
- Ajuste de brillo (factor $\in [0,8, 1,2]$).
- Ajuste de contraste (factor $\in [0,8, 1,2]$).
- Rotación horizontal combinado con rotación leve ($\pm 20^\circ$).
- Desenfoque gaussiano suave (radio $\in [0,5, 1,2]$), que simula capturas con ligero movimiento en campo.

El padding (relleno de color negro) en las rotaciones se elige deliberadamente: tras la normalización ImageNet, el valor (0, 0, 0) es interpretado por el modelo como ausencia de información, evitando que las esquinas introducidas por la rotación sean tratadas como contenido visual real.

6.3. Undersampling de las clases mayoritarias

Con el fin de balancear entre sí las tres clases mayoritarias, sin alterar el volumen de nemátodos que ya había sido llevado a 500 mediante augmentation, se aplica undersampling aleatorio sobre las clases 0, 1 y 3, fijando un tope de 1.250 imágenes por clase. El resultado es una distribución intencional de 1500 : 1500 : 500 : 1500 imágenes entre hoja sana, tizón tardío, nemátodos y tizón temprano, respectivamente. Este desbalance residual entre nemátodos y las demás clases se aborda en la función de pérdida mediante pesos de clase (véase la Sección 6.8).

¹Durante la preparación de este documento no fue posible identificar con certeza la totalidad de las fuentes de datos utilizadas en una versión preliminar del proyecto. En consecuencia, y con el fin de garantizar la trazabilidad y reproducibilidad de los resultados, el sistema fue reentrenado por completo utilizando las cuatro fuentes públicas verificadas que se describen a continuación. Los resultados reportados en este trabajo corresponden íntegramente a dicho reentrenamiento.

6.4. Preprocesamiento: padding simétrico y redimensionado

Las imágenes presentan relaciones de aspecto heterogéneas, resultado del recorte individual de cada hoja siguiendo su contorno natural. Aplicar un redimensionado directo a 224×224 píxeles distorsionaría las proporciones reales de la hoja, comprometiendo la generalización del modelo ante imágenes capturadas en campo sin esa distorsión artificial.

La solución implementada aplica padding simétrico previo al redimensionado sobre cada imagen, siguiendo estos pasos:

1. Se identifica la dimensión mayor ($\max(\text{ancho}, \text{alto})$).
2. Se añaden píxeles negros (0, 0, 0) de forma simétrica en la dimensión menor hasta obtener una imagen cuadrada.
3. Se aplica `resize` a 224×224 píxeles con interpolación LANCZOS.

Este preprocesamiento se aplica a la totalidad de las imágenes, incluidas las generadas por augmentation, antes de la división en particiones.

6.5. División del dataset

El dataset preprocesado se divide en tres particiones mediante muestreo estratificado que preserva la distribución de clases en cada subconjunto: 70 % entrenamiento, 15 % validación y 15 % prueba, fijando una semilla aleatoria (`SEED = 20`) para garantizar la reproducibilidad. El split resultante se comprime y guarda en Google Drive para su reutilización en sesiones posteriores.

El Experimento B parte de este mismo split: se elimina únicamente la carpeta de la clase 2 en las tres particiones, garantizando que las imágenes de hoja sana, tizón tardío y tizón temprano sean idénticas en ambos experimentos y que la comparativa entre 4 y 3 clases sea estrictamente controlada.

6.6. Transformaciones durante el entrenamiento

Sobre el conjunto de entrenamiento se aplica un pipeline de augmentation en línea (*on-the-fly*) para simular variabilidad de captura en campo:

- Volteo horizontal ($p = 0,5$) y vertical ($p = 0,3$).
- Rotación aleatoria $\pm 30^\circ$.
- Color Jitter : brillo, contraste y saturación $\pm 0,3$; tono $\pm 0,1$.
- Traslación aleatoria ($\pm 10\%$ en ambos ejes).
- Normalización ImageNet: media [0,485, 0,456, 0,406], desviación estándar [0,229, 0,224, 0,225].

Los conjuntos de validación y prueba reciben únicamente `resize` y normalización ImageNet, sin augmentation.

6.7. Arquitectura: EfficientNet-B0

Se emplea EfficientNet-B0 preentrenado en ImageNet como *backbone*. La selección de esta arquitectura responde a su destacada relación entre exactitud y costo computacional: con apenas 20 MB de parámetros, alcanza un rendimiento comparable al de arquitecturas considerablemente más pesadas en tareas de clasificación de enfermedades foliares. Alternativas como VGG16 y ViT alcanzan exactitudes similares pero con modelos de 528 MB y 330 MB respectivamente, lo que los hace inviables para despliegue en dispositivos móviles o entornos con recursos limitados [8]. MobileNetV2, aunque más liviano (14 MB), sacrifica varios puntos porcentuales de exactitud. La ventaja intrínseca de EfficientNet reside en su estrategia de escalado compuesto: en lugar de aumentar únicamente la profundidad de la red como hacen arquitecturas tradicionales, escala simultáneamente profundidad, anchura y resolución de entrada mediante un coeficiente balanceado, lo que se traduce en mayor eficiencia por parámetro [25]. Esta combinación de ligereza y rendimiento la convierte en la opción más adecuada para el contexto del presente trabajo, donde se contempla el despliegue futuro del sistema en dispositivos de campo accesibles para pequeños productores. La cabeza clasificadora original, diseñada para 1.000 clases de ImageNet, se reemplaza por una red densa adaptada al problema, compuesta secuencialmente por: Dropout(0,4), Linear(1280 $\rightarrow$ 256), ReLU, Dropout(0,3) y Linear(256 $\rightarrow$ N), donde $N = 4$ para el Experimento A y $N = 3$ para el Experimento B.

6.8. Protocolo de entrenamiento en dos fases

Cada experimento sigue un esquema de transfer learning progresivo en dos fases secuenciales de 30 épocas cada una, para un total de 60 épocas por experimento.

Fase 1: Backbone congelado (30 épocas)

El backbone se congela completamente y solo se actualizan los parámetros de la cabeza clasificadora, permitiendo adaptar las capas finales al dominio específico sin perturbar las representaciones generales aprendidas en ImageNet. Los componentes del entrenamiento son:

- Optimizador: Adam, $lr = 1 \times 10^{-4}$, weight decay = 1×10^{-4} .
- Función de pérdida (Experimento A): **CrossEntropyLoss** con pesos inversamente proporcionales al tamaño de cada clase en entrenamiento, para penalizar más los errores sobre nemátodos.
- Función de pérdida (Experimento B): **CrossEntropyLoss** estándar, dado que las tres clases están balanceadas.
- Scheduler: **ReduceLROnPlateau** (modo **max**, factor 0,5, paciencia de 5 épocas sin mejora en **val_acc**).
- El mejor modelo según **val_acc** se guarda en disco al término de cada época.

Fase 2: Fine-tuning completo (30 épocas)

Se descongelan todos los parámetros de la red y se continúa desde los pesos guardados al final de la Fase 1, con tasa de aprendizaje reducida para no deteriorar las representaciones preentrenadas:

- Optimizador: Adam, $lr = 1 \times 10^{-5}$, weight decay = 1×10^{-4} .
- Función de pérdida y scheduler: idénticos a la Fase 1.
- El mejor modelo de la Fase 2 se guarda de forma independiente al de la Fase 1.

Los historiales de pérdida y exactitud de ambas fases se concatenan para visualizarlos como una curva continua de 60 épocas, con una línea vertical en la época 30 marcando el inicio del fine-tuning.

6.9. Evaluación y análisis de resultados

Cada experimento produce dos modelos guardados independientemente (Fase 1 y Fase 2), dando un total de cuatro modelos evaluados. La evaluación se realiza siempre sobre el conjunto de prueba denominado 'test' (dataset el cual no fue visto durante el entrenamiento ni la validación por el modelo) mediante los siguientes instrumentos:

7. Resultados

Esta sección presenta los resultados obtenidos por los cuatro modelos evaluados, correspondientes a la Fase 1 y Fase 2 del Experimento A (4 clases) y del Experimento B (3 clases), sobre el conjunto de prueba, el cual no fue utilizado en ningún momento durante el entrenamiento ni la validación.

7.1. Curvas de entrenamiento

Las Fig. 2 y 3 presentan la evolución de la pérdida y la exactitud en entrenamiento y validación a lo largo de las 60 épocas de cada experimento. La línea vertical en la época 30 delimita el inicio de la Fase 2 (fine-tuning completo).




Figura 2: Curvas de entrenamiento del Experimento A (4 clases): pérdida y exactitud en entrenamiento y validación durante las 60 épocas. La línea vertical marca el inicio del fine-tuning.




Figura 3: Curvas de entrenamiento del Experimento B (3 clases): pérdida y exactitud en entrenamiento y validación durante las 60 épocas. La línea vertical marca el inicio del fine-tuning.

7.2. Métricas de clasificación

La Tabla 1 y la Tabla 2 reportan precisión, recall y F1-score por clase, junto con la exactitud global ponderada, para los modelos de Fase 1 y Fase 2 de cada experimento.

Cuadro 1: Métricas de clasificación: Experimento A (4 clases)

Clase	Fase	Precisión	Recall	F1
Hoja sana	1	0.9391	0.9558	0.9474
	2	0.9869	1	0.9934
Tizón tardío	1	0.9450	0.9115	0.9279
	2	1	0.9735	0.9865
Nemátodos	1	0.9615	0.9868	0.9740
	2	1	1	1
Tizón temprano	1	0.9561	0.9646	0.9604
	2	0.9825	0.9956	0.9890
Global	1	Exactitud: 94.83 %		
	2	Exactitud: 99.07 %		

Cuadro 2: Métricas de clasificación del Experimento B (3 clases)

Clase	Fase	Precisión	Recall	F1
Hoja sana	1	0.9402	0.9735	0.9565
	2	0.9869	1	0.9934
Tizón tardío	1	0.9399	0.9690	0.9542
	2	0.9825	0.9912	0.9868
Tizón temprano	1	0.9526	0.8894	0.9199
	2	0.9955	0.9735	0.9843
Global	1	Exactitud: 94.40 %		
	2	Exactitud: 98.82 %		

7.3. Matrices de confusión

Las Fig. 4 a 7 presentan las matrices de confusión normalizadas de los cuatro modelos evaluados sobre el conjunto de prueba.




Figura 4: Matriz de confusión del Experimento A, Fase 1 (backbone congelado, 4 clases).




Figura 5: Matriz de confusión del Experimento A, Fase 2 (fine-tuning completo, 4 clases).




Figura 6: Matriz de confusión del Experimento B, Fase 1 (backbone congelado, 3 clases).




Figura 7: Matriz de confusión del Experimento B, Fase 2 (fine-tuning completo, 3 clases).

7.4. Predicciones individuales

Las Fig. 8 y 9 muestran 8 imágenes aleatorias del conjunto de prueba con la etiqueta real y la predicción del modelo de Fase 2. El borde verde indica acierto y el borde rojo indica error de clasificación.




Figura 8: Muestras de predicciones individuales en el Experimento A (4 clases). Verde: predicción correcta. Rojo: predicción incorrecta.




Figura 9: Muestras de predicciones individuales en el Experimento B (3 clases). Verde: predicción correcta. Rojo: predicción incorrecta.

8. Discusión

El principal reto metodológico del presente trabajo residió en la escasez crítica de imágenes de la clase nemátodos, que originalmente contaba con tan solo 90 muestras, frente a volúmenes considerablemente mayores en las demás clases. Esta disparidad introduce un sesgo estructural durante el entrenamiento, ya que el modelo tiende a minimizar la pérdida global ignorando la clase minoritaria, cuya contribución al error total resulta proporcionalmente reducida. Para mitigar este problema, se implementaron dos mecanismos complementarios: data augmentation selectivo aplicado exclusivamente a la clase nemátodos, incrementando su volumen hasta 500 imágenes mediante transformaciones que preservan la información cromática diagnóstica, y una función de pérdida **CrossEntropyLoss** ponderada con pesos inversamente proporcionales al tamaño de cada clase, de manera que los errores asociados a los nemátodos recibieran una mayor penalización durante el proceso de aprendizaje.

Los resultados del Experimento A evidencian la efectividad de esta estrategia. La clase nemátodos alcanzó un recall de 0.9868 en la Fase 1 y un valor de 1.0000 en la Fase 2, acompañado de valores de F1-score de 0.9740 y 1.0000, respectivamente. Las matrices de confusión corroboran este comportamiento: en la Fase 1 se registró una única clasificación incorrecta en esta clase (1 instancia confundida con hoja sana), mientras que en la Fase 2 la diagonal es perfecta (76/76 instancias correctas). Estos resultados indican que el modelo no omitió ninguna instancia real de nemátodos en el conjunto de prueba tras el fine-tuning, un aspecto particularmente relevante desde el punto de vista fitosanitario, debido a las consecuencias agronómicas directas asociadas a los falsos negativos.

En cuanto al esquema de transfer learning progresivo, el fine-tuning produjo mejoras consistentes en todos los modelos evaluados. En el Experimento A la exactitud global pasó de 94.83 % en la Fase 1 a 99.07 % en la Fase 2, una ganancia de 4.24 puntos porcentuales; en el Experimento B, de 94.40 % a 98.82 %, una ganancia de 4.42 puntos porcentuales. A nivel de clase, las ganancias más notables se observan en tizón tardío: su F1-score aumentó de 0.9279 a 0.9865 en el Experimento A y de 0.9542 a 0.9868 en el Experimento B, siendo esta la clase que presentó mayor dificultad para el modelo con backbone congelado. En la Fase 1 del Experimento A, tizón tardío registró 10 clasificaciones incorrectas como hoja sana, 1 como nemátodos y 9 como tizón temprano; tras el fine-tuning, estos errores se redujeron a 2, 0 y 4 respectivamente, confirmando la capacidad del fine-tuning para refinar los límites de decisión entre clases visualmente similares.

Que la mejora sea real pero acotada resulta coherente con la naturaleza del problema, ya que EfficientNet-B0 preentrenado en ImageNet posee representaciones de bajo y medio nivel, tales como bordes, texturas y gradientes

de color, altamente transferibles al dominio foliar. La Fase 1 es suficiente para adaptar la cabeza clasificadora a las particularidades del dataset, mientras que la Fase 2 refina los pesos intermedios del backbone, mejorando el rendimiento sin introducir sobreajuste visible. Esta observación se encuentra respaldada por las curvas de entrenamiento, donde la brecha entre la pérdida de entrenamiento y la pérdida de validación permanece acotada a lo largo de las 60 épocas.

Dado que ambos experimentos operan sobre exactamente las mismas imágenes de hoja sana, tizón tardío y tizón temprano, la comparativa entre ellos permite aislar el efecto de incorporar la clase nemátodos sobre el rendimiento general del sistema. Los resultados revelan que dicho efecto es reducido: las exactitudes globales de Fase 1 difieren en 0.43 puntos porcentuales (94.83 % vs. 94.40 %), y las de Fase 2 en 0.25 puntos porcentuales (99.07 % vs. 98.82 %). A nivel de clase, las métricas de hoja sana, tizón tardío y tizón temprano son comparables entre ambos experimentos, sin degradación sistemática atribuible a la presencia de nemátodos. Este hallazgo constituye uno de los aportes más relevantes del trabajo: la incorporación de una clase con desbalance severo y representación artificialmente aumentada no compromete la capacidad del modelo para discriminar las clases mayoritarias, siempre que se apliquen estrategias de compensación adecuadas. Desde una perspectiva práctica, esto valida la viabilidad de construir un sistema de cuatro clases operacionalmente útil incluso bajo condiciones de escasez severa de datos para una de las patologías objetivo.

Las matrices de confusión corroboran cuantitativamente estas tendencias. En el Experimento A, Fase 1, el principal foco de error se concentra en hoja sana, con 7 instancias clasificadas como tizón tardío, 2 como nemátodos y 1 como tizón temprano, y en tizón tardío, con 10 clasificaciones como hoja sana, 1 como nemátodos y 9 como tizón temprano. Tras el fine-tuning, estos patrones de error se reducen sustancialmente: hoja sana no registra ningún error (226/226 correctas) y tizón tardío acumula únicamente 6 clasificaciones incorrectas. En el Experimento B, Fase 1, hoja sana presenta 5 confusiones con tizón temprano y 1 con tizón tardío, mientras que tizón temprano registra 12 confusiones con hoja sana y 13 con tizón tardío; tras el fine-tuning estos errores se reducen drásticamente, con hoja sana sin ningún error total y tizón temprano acumulando 6, lo que confirma que el fine-tuning mejora especialmente la discriminación entre clases con apariencia foliar similar.

Finalmente, los resultados obtenidos son consistentes con los reportados en la literatura especializada. Mohanty et al. [7] reportaron exactitudes superiores al 99 % sobre el dataset PlantVillage en condiciones de laboratorio, y Ferentinos [8] alcanzó hasta 99.53 % con arquitecturas CNN profundas sobre el mismo benchmark. Los valores obtenidos en el presente trabajo (99.07 % y 98.82 % en Fase 2) son comparables a estos referentes, con la diferencia significativa de que se trabaja sobre imágenes combinadas de múltiples fuentes con variabilidad natural de fondo, iluminación y morfología foliar, y con una clase adicional de origen parasitario que no suele contemplarse en los benchmarks estándar. No obstante, deben reconocerse las limitaciones del trabajo: la clase nemátodos se construyó a partir de augmentation sobre 90 imágenes originales, lo que implica que las 500 muestras resultantes no son estadísticamente independientes y el modelo puede haber aprendido artefactos específicos de ese conjunto reducido. Una validación robusta requeriría imágenes capturadas en condiciones distintas a las del entrenamiento. Como trabajo futuro se propone ampliar la base de datos de nemátodos mediante colaboración con instituciones agrícolas regionales, explorar arquitecturas de mayor capacidad como EfficientNet-B4 o modelos basados en Vision Transformers, y desarrollar una interfaz de despliegue en dispositivos móviles orientada a pequeños productores del departamento de Sucre.

Referencias

- [1] Food and Agriculture Organization of the United Nations (FAO), “Potatoes: So Familiar, So Much More to Learn,” 2025. [Online]. Available: <https://www.fao.org/publications/news-archive/detail/potatoes-so-familiar-so-much-more-to-learn/en>
- [2] Instituto Colombiano Agropecuario (ICA), “El cultivo de papa, clave para la seguridad alimentaria, hambre cero y fortalecimiento del campo,” 2024. [Online]. Available: <https://www.ica.gov.co>
- [3] S. Dong and S. Zhou, “Potato late blight caused by *Phytophthora infestans*: From molecular interactions to integrated management strategies,” *Journal of Integrative Agriculture*, vol. 21, no. 12, pp. 3456–3466, 2022. doi: 10.1016/j.jia.2022.08.060.

- [4] A. K. Chaerani and R. E. Voorrips, “Tomato early blight (*Alternaria solani*): the pathogen, genetics, and breeding for resistance,” *Journal of General Plant Pathology*, vol. 72, no. 6, pp. 335–347, 2006. doi: 10.1007/s10327-006-0299-3.
- [5] N. C. Gudmestad, O. Pasche, and L. M. Wharam, “Management of Early Blight in Potato,” *Plant Health Progress*, vol. 14, no. 1, 2013. doi: 10.1094/PHP-2013-0325-01-RV.
- [6] M. Obando, G. Torres, and L. E. Rodríguez, “Control de *Globodera pallida* en papa en Colombia,” *Rev. Latinoamericana Papa*, vol. 21, no. 1, 2017.
- [7] S. P. Mohanty, D. P. Hughes, and M. Salathé, “Using deep learning for image-based plant disease detection,” *Frontiers in Plant Science*, vol. 7, p. 1419, 2016. doi: 10.3389/fpls.2016.01419.
- [8] K. P. Ferentinos, “Deep learning models for plant disease detection and diagnosis,” *Computers and Electronics in Agriculture*, vol. 145, pp. 311–318, 2018. doi: 10.1016/j.compag.2018.01.009.
- [9] A. S. Abade, P. A. Ferreira, and F. B. Vidal, “Plant Diseases Recognition on Images using Convolutional Neural Networks: A Systematic Review,” *arXiv preprint arXiv:2009.04365*, 2020. [Online]. Available: <https://arxiv.org/abs/2009.04365>
- [10] Fondo Nacional de Fomento a la Papa, “Estadísticas de producción mundial de papa 2023,” Fedepapa, 2024. [Online]. Available: <https://www.fedepapa.com>
- [11] N. Greco, “Potato cyst nematodes,” in *Plant Parasitic Nematodes in Temperate Agriculture*. Wallingford: CAB International, 1993, pp. 149–180.
- [12] J. Franco and A. González, *Daño y manejo de nemátodos en papa*. Lima: Centro Internacional de la Papa (CIP), 2011.
- [13] R. Thevenoux, J. M. Risède, and M. Tchamitchian, “Integrated pest management and nematodes,” *Eur. J. Agronomy*, vol. 115, p. 126017, 2020. doi: 10.1016/j.eja.2020.126017
- [14] FEDEPAPA, “Estadísticas del cultivo de papa en Colombia,” Federación Colombiana de Productores de Papa, 2020. [Online]. Available: <https://www.fedepapa.com>
- [15] C. Betancourth, “Eficacia de fluensulfona en el control de *Globodera pallida* (Stone) Behrens en el cultivo de papa (*Solanum tuberosum* L.) en Nariño (Colombia),” *Inform. Tecnológica*, vol. 33, no. 2, pp. 107–116, 2022. doi: 10.4067/S0718-07642022000200107
- [16] O. A. Guerrero, “El nemátodo quiste de la papa (*Globodera pallida*): detección y manejo en Colombia,” ICA, Servicio Sanidad Vegetal, 1982.
- [17] H. Nieto, “Distribución y densidad de poblaciones de nemátodos en papa en Nariño,” in *Proc. Simposio Nemátodos Papa*, Pasto, Colombia, 1983.
- [18] “Manejo integrado de plagas y enfermedades en el cultivo de papa (*Solanum tuberosum* L.) para una mayor seguridad alimentaria de pequeños productores en el altiplano cundiboyacense, Colombia,” ResearchGate, 2019. [Online]. Available: <https://doi.org/10.13140/RG.2.2.36097.71526>
- [19] Plan Departamental de Extensión Agropecuaria del departamento de Sucre, “PDEA Sucre 2024,” Agencia de Desarrollo Rural (ADR), 2024. [Online]. Available: https://www.adr.gov.co/wp-content/uploads/2024/08/01_PDEA_SUCRE.2024.pdf
- [20] J. G. A. Barbedo, “Factors influencing the use of deep learning for plant disease recognition,” *Biosystems Engineering*, vol. 172, pp. 84–91, 2018. doi: 10.1016/j.biosystemseng.2018.05.013.
- [21] “Multi-Crop Leaf Disease Dataset: Corn, Potato, Rice, Tomato, and Cashew,” Mendeley Data, 2024. [Online]. Available: <https://data.mendeley.com/datasets/z6jp232g5j/1>
- [22] Arun Pandian and G. Gopal, “PlantVillage Dataset,” Kaggle, 2018. [Online]. Available: <https://www.kaggle.com/datasets/emmarex/plantdisease>
- [23] N. Sankalana, “Potato Leaf (Healthy and Late Blight),” Kaggle, 2024. [Online]. Available: <https://www.kaggle.com/datasets/nimalsankalana/potato-leaf-healthy-and-late-blight>

- [24] “Potato Computer Vision Model,” Roboflow Universe, 2024. [Online]. Available: <https://universe.roboflow.com/ai-xwoe2/potato-eq4aq>
- [25] M. Tan and Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” in *Proc. 36th Int. Conf. Machine Learning (ICML)*, Long Beach, CA, USA, 2019, pp. 6105–6114. [Online]. Available: <https://arxiv.org/abs/1905.11946>